Modelo para o Sensor CEI

Este dataset "DataCEI.csv" possui informações dispostas em colunas sobre as características dos objetos que passam pelo sensor:

- **Tamanho:** Segue a classificação do CEI2020 (Tamanho='0' - Grande 100%).
- **Referencia:** Referência dinâmica do *Threshold.
- **NumAmostra:** Número de amostras adquiridas.
- **Area:** Somatório das Amplitudes das amostras.
- **Delta:** Máxima Amplitude da amostra.
- **Output1:** Peça tipo 1.
- **Output2:** Peça tipo 2.

Bibliotecas

In [1]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline

#Função do cáculo da sigmóide
def sigmoid(x):
    return 1/(1+np.exp(-x))
```

Carregando os dados

Vamos começar lendo o arquivo DataCEI.csv em um dataframe do pandas.

In [2]:

```
DataSet=pd.read_csv('arruela.csv')
```

In [3]:

```
DataSet.head()
```

Out[3]:

	Hora	Tamanho	Referencia	NumAmostra	Area	Delta	Output1	Output2
0	17:56:39	53	25	69	81	68	1	0
1	17:56:41	53	26	89	87	56	1	0
2	17:56:52	53	27	68	69	55	1	0
3	17:56:58	53	29	71	72	50	1	0
4	17:57:04	53	30	71	61	41	1	0

In [4]:

```
DataSet.drop(['Hora','Tamanho','Referencia'],axis=1,inplace=True)
```

In [5]:

```
DataSet.head()
```

Out[5]:

	NumAmostra	Area	Delta	Output1	Output2

	NumAmostra	Area	Delta	Output1	Output2
0	69	81	68	1	0
1	89	87	56	1	0
2	68	69	55	1	0
3	71	72	50	1	0
4	71	61	41	1	0

In [6]:

```
DataSet.describe()
```

Out[6]:

	NumAmostra	Area	Delta	Output1	Output2
count	257.000000	257.000000	257.000000	257.000000	257.000000
mean	59.840467	63.743191	54.571984	0.365759	0.634241
std	16.789885	30.741427	35.690670	0.482582	0.482582
min	3.000000	6.000000	17.000000	0.000000	0.000000
25%	50.000000	46.000000	38.000000	0.000000	0.000000
50%	59.000000	56.000000	44.000000	0.000000	1.000000
75%	69.000000	68.000000	53.000000	1.000000	1.000000
max	110.000000	201.000000	251.000000	1.000000	1.000000

Váriaveis do *Dataset*

In [7]:

```
DataSet.columns
```

Out[7]:

```
Index(['NumAmostra', 'Area', 'Delta', 'Output1', 'Output2'], dtype='object')
```

Número de Peças

Vamos classificar os grupos pelo número de peças:

1. **Grupo com uma peça**
2. **Grupo com duas peças**

In [8]:

```
sns.set_style('whitegrid')
sns.countplot(x='Output2',data=DataSet,palette='RdBu_r')
plt.show()
```

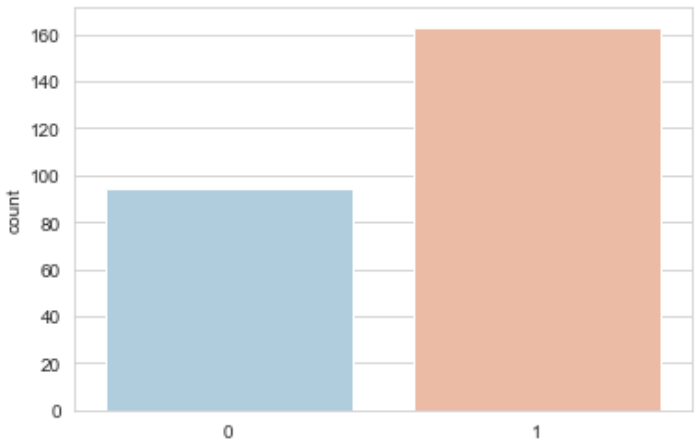

Output2

Gráfico da distribuição das áreas das peças

In [9]:

```
sns.distplot(DataSet['Area'].dropna(),kde=False,color='darkred',bins=30)
plt.show()
```

```
c:\users\rodrigo\appdata\local\programs\python\python38\lib\site-packages\seaborn\distribu
tions.py:2557: FutureWarning: `distplot` is a deprecated function and will be removed in
a future version. Please adapt your code to use either `displot` (a figure-level function
with similar flexibility) or `histplot` (an axes-level function for histograms).
  warnings.warn(msg, FutureWarning)
```

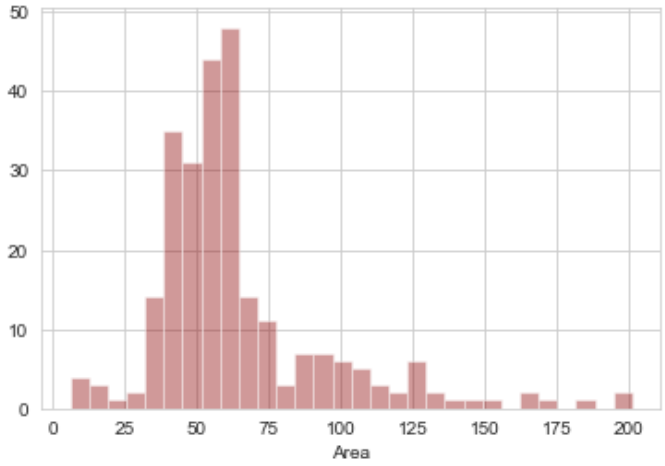

In [10]:

```
sns.set_style('whitegrid')
sns.countplot(x='Area',hue='Output2',data=DataSet,palette='rainbow')
plt.show()
```

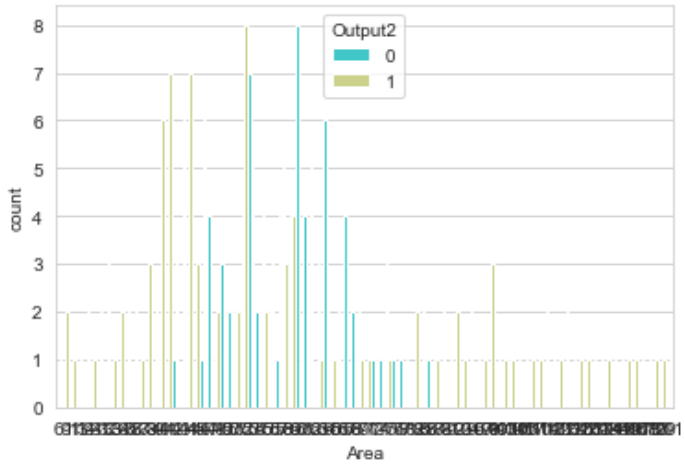

In [11]:

```
sns.set_style('whitegrid')
sns.countplot(x='NumAmostra',hue='Output2',data=DataSet,palette='rainbow')
plt.show()
```

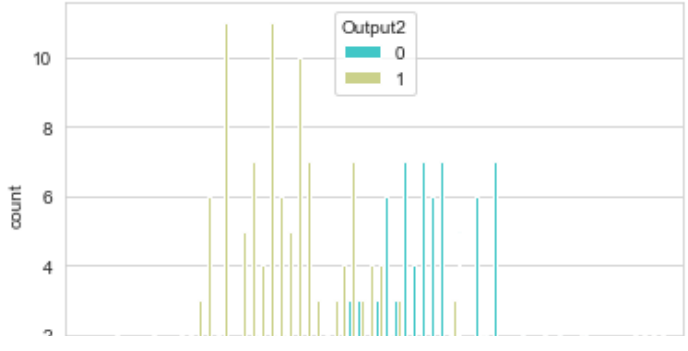

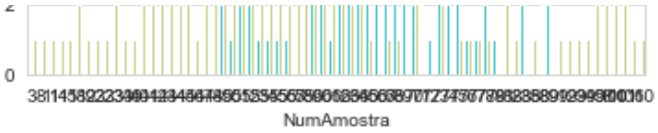

In [12]:

```
sns.set_style('whitegrid')
sns.countplot(x='Delta',hue='Output1',data=DataSet,palette='rainbow')
plt.show()
```

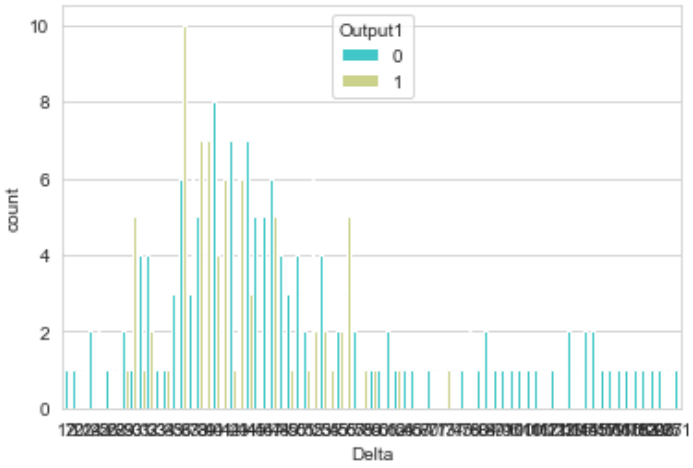

As variáveis preditoras e a variável de resposta

Para treinar o modelo de regressão, primeiro precisaremos dividir nossos dados em uma matriz X que contenha os dados das variáveis preditoras e uma matriz y com os dados da variável de destino.

Matrizes X e y

In [13]:

```
#X = DataSet[[ 'NumAmostra', 'Area', 'Delta']]
#y = DataSet[['Output1','Output2']]
```

Relação entre as variáveis preditoras

Algumas questões importantes

1. **Pelo menos um dos preditores *x1, x2, ... ,x5* é útil na previsão da resposta?**
2. **Todos os preditores ajudam a explicar y, ou apenas um subconjunto dos preditores?**
3. **Quão bem o modelo se ajusta aos dados?**
4. **Dado um conjunto de valores de previsão, quais valores de resposta devemos prever e quais as métricas indicam um bom modelo de previsão?**

Gráficos simples de dispersão

Pelos gráficos abaixo percebemos ... nossa variável de resposta

In [14]:

```
sns.pairplot(DataSet)
plt.show()
```

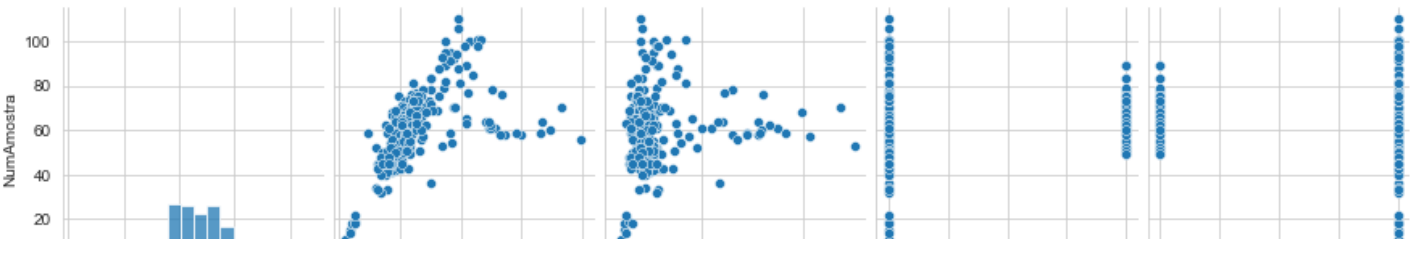

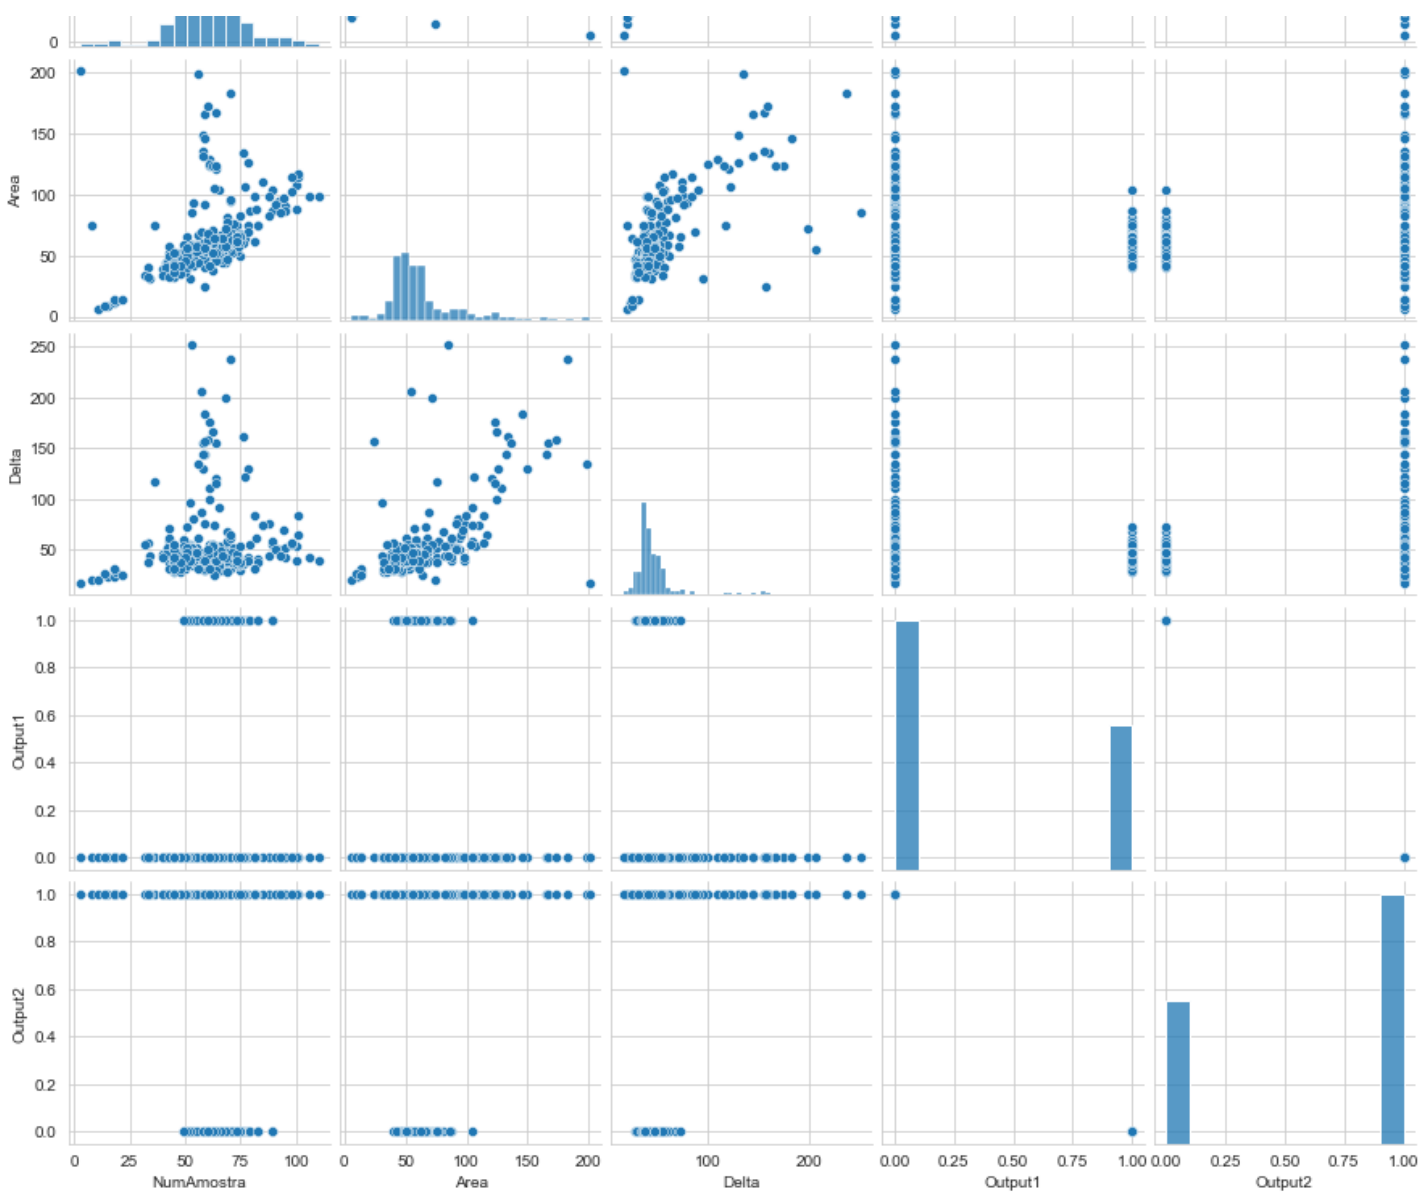

Mapa de Calor

O gráfico abaixo mostra através de uma escala de cores a correlação entre as variáveis do *Dataset*. Se observarmos as cores deste gráfico, a variável preditora 'Area' possui maior correlação com a variável de resposta 'Output' e a variável 'NumAmostra' a menor.

In [15]:

```
sns.heatmap(DataSet.corr())
plt.show()
```

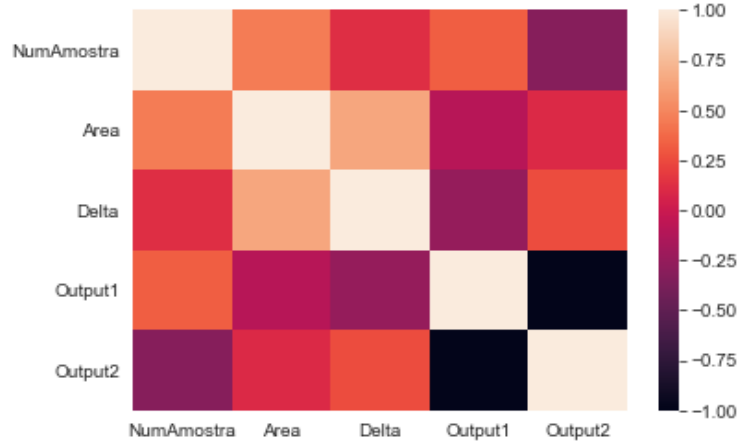

Normalização dos Dados

In [16]:

In [16]:

```
from sklearn.preprocessing import StandardScaler
scaler=StandardScaler()
DataScaled=scaler.fit_transform(DataSet)
DataSetScaled=pd.DataFrame(np.array(DataScaled),columns = ['NumAmostra', 'Area', 'Delta'
, 'Output1','Output2'])
```

In [17]:

```
DataSetScaled.head()
```

Out[17]:

	NumAmostra	Area	Delta	Output1	Output2
0	**0.546603**	**0.562449**	**0.376967**	**1.31683**	**-1.31683**
1	**1.740121**	**0.758006**	**0.040089**	**1.31683**	**-1.31683**
2	**0.486927**	**0.171334**	**0.012016**	**1.31683**	**-1.31683**
3	**0.665955**	**0.269113**	**-0.128350**	**1.31683**	**-1.31683**
4	**0.665955**	**-0.089408**	**-0.381009**	**1.31683**	**-1.31683**

Conjunto de dados para o treinamento

In [18]:

```
X = DataSetScaled.drop(['Output1', 'Output2'],axis=1)
y = DataSet[['Output1','Output2']]
```

Separando os dados de treinamento e de validação

Agora vamos dividir os dados em um conjunto de treinamento e um conjunto de testes. Vamos treinar o modelo no conjunto de treinamento, em seguida, usar o conjunto de teste para validar o modelo.

Em nosso exemplo iremos separar de forma randômica 33% dos dados para validação. Estes dados não serão utilizados para determinação dos coeficientes preditores do modelo.

In [19]:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.30, random_state=1
01)

print(y_test)
print(X_test)
```

```
     Output1  Output2
169        0        1
161        0        1
69         1        0
223        0        1
93         1        0
..       ...      ...
255        0        1
65         1        0
154        0        1
54         1        0
66         1        0

[78 rows x 2 columns]
     NumAmostra      Area     Delta
169    2.098176  0.758006 -0.352936
161    0.128872  0.236520  0.012016
69     0.427251 -0.089408 -0.296789
223   -3.093626  0.334299 -0.970546
93    -0.646914 -0.447930 -0.212570
```

```
..          ...       ...       ...
255   -0.885618 -0.904230 -0.633668
65     0.188548 -0.122001 -0.381009
154   -0.408211 -0.350151 -0.324863
54    -0.229183  0.106149  0.208528
66     0.844983 -0.024223 -0.324863

[78 rows x 3 columns]
```

Criando o Modelo de MPL

In [20]:

```
#Tamanho do DataSet de Treinamento
n_records, n_features = X_train.shape

#Arquitetura da MPL
N_input = 3
#N_hidden = 4
N_hidden = 4
N_output = 2
#learnrate = 0.1
learnrate = 0.5
```

Inicialização dos pesos da MPL (Aleatório)

In [21]:

```
#Pesos da Camada Oculta (Inicialização Aleatória)
weights_input_hidden = np.random.normal(0, scale=0.1, size=(N_input, N_hidden))
print('Pesos da Camada Oculta:')
print(weights_input_hidden)

#Pesos da Camada de Saída (Inicialização Aleatória)
weights_hidden_output = np.random.normal(0, scale=0.1, size=(N_hidden, N_output))
print('Pesos da Camada de Saída:')
print(weights_hidden_output)
```

```
Pesos da Camada Oculta:
[[-0.01111525 -0.04267299  0.06573512  0.01013728]
 [ 0.0073134   0.00021853 -0.15705017 -0.01390683]
 [-0.02013369 -0.08615575  0.0415067   0.12830932]]
Pesos da Camada de Saída:
[[-0.002859   -0.00237002]
 [-0.04772709  0.11000549]
 [-0.04811484 -0.07558371]
 [ 0.10665925 -0.01856265]]
```

Algoritmo Backpropagation

In [22]:

```
epochs = 20000
#epochs = 35000
last_loss=None
EvolucaoError=[]
IndiceError=[]

for e in range(epochs):
    delta_w_i_h = np.zeros(weights_input_hidden.shape)
    delta_w_h_o = np.zeros(weights_hidden_output.shape)
    for xi, yi in zip(X_train.values, y_train.values):

# Forward Pass
        #Camada oculta
        #Calcule a combinação linear de entradas e pesos sinápticos
        hidden_layer_input = np.dot(xi, weights_input_hidden)
```

```
        #Aplicado a função de ativação
        hidden_layer_output = sigmoid(hidden_layer_input)

        #Camada de Saída
        #Calcule a combinação linear de entradas e pesos sinápticos
        output_layer_in = np.dot(hidden_layer_output, weights_hidden_output)

        #Aplicado a função de ativação
        output = sigmoid(output_layer_in)
        #print('As saídas da rede são',output)
#-----------------------------------------

# Backward Pass
        ## TODO: Cálculo do Erro
        error = yi - output

        # TODO: Calcule o termo de erro de saída (Gradiente da Camada de Saída)
        output_error_term = error * output * (1 - output)

        # TODO: Calcule a contribuição da camada oculta para o erro
        hidden_error = np.dot(weights_hidden_output,output_error_term)

        # TODO: Calcule o termo de erro da camada oculta (Gradiente da Camada Oculta)
        hidden_error_term = hidden_error * hidden_layer_output * (1 - hidden_layer_outpu
t)

        # TODO: Calcule a variação do peso da camada de saída
        delta_w_h_o += output_error_term*hidden_layer_output[:, None]

        # TODO: Calcule a variação do peso da camada oculta
        delta_w_i_h += hidden_error_term * xi[:, None]

    #Atualização dos pesos na época em questão
    weights_input_hidden += learnrate * delta_w_i_h / n_records
    weights_hidden_output += learnrate * delta_w_h_o / n_records


    # Imprimir o erro quadrático médio no conjunto de treinamento

    if  e % (epochs / 20) == 0:
        hidden_output = sigmoid(np.dot(xi, weights_input_hidden))
        out = sigmoid(np.dot(hidden_output,
                             weights_hidden_output))
        loss = np.mean((out - yi) ** 2)

        if last_loss and last_loss < loss:
            print("Erro quadrático no treinamento: ", loss, " Atenção: O erro está aumen
tando")
        else:
            print("Erro quadrático no treinamento: ", loss)
        last_loss = loss

        EvolucaoError.append(loss)
        IndiceError.append(e)
```

```
Erro quadrático no treinamento:  0.25511400660649497
Erro quadrático no treinamento:  0.2139723387613303
Erro quadrático no treinamento:  0.06327361494170093
Erro quadrático no treinamento:  0.037384054258786374
Erro quadrático no treinamento:  0.028229918690453264
Erro quadrático no treinamento:  0.02009432913589116
Erro quadrático no treinamento:  0.01580275511230584
Erro quadrático no treinamento:  0.013526581129013449
Erro quadrático no treinamento:  0.012370077062884321
Erro quadrático no treinamento:  0.01164155031613999
Erro quadrático no treinamento:  0.010521104719093892
Erro quadrático no treinamento:  0.009060703249999882
Erro quadrático no treinamento:  0.007559452643242686
Erro quadrático no treinamento:  0.0061777764409276185
Erro quadrático no treinamento:  0.0050353940623455214
Erro quadrático no treinamento:  0.004128692458058931
Erro quadrático no treinamento:  0.0034115320854725237
```

```
Erro quadrático no treinamento:  0.00283881830879886
Erro quadrático no treinamento:  0.0023759243129256747
Erro quadrático no treinamento:  0.001997562691519123
```

In [23]:

```
### Gráfico da Evolução do Erro
```

In [24]:

```
plt.plot(IndiceError, EvolucaoError, 'r') # 'r' is the color red
plt.xlabel('')
plt.ylabel('Erro Quadrático')
plt.title('Evolução do Erro no treinamento da MPL')
plt.show()
```

Validação do modelo

In [25]:

```
# Calcule a precisão dos dados de teste
n_records, n_features = X_test.shape
predictions=0

for xi, yi in zip(X_test.values, y_test.values):

# Forward Pass
        #Camada oculta
        #Calcule a combinação linear de entradas e pesos sinápticos
        hidden_layer_input = np.dot(xi, weights_input_hidden)
        #Aplicado a função de ativação
        hidden_layer_output = sigmoid(hidden_layer_input)

        #Camada de Saída
        #Calcule a combinação linear de entradas e pesos sinápticos
        output_layer_in = np.dot(hidden_layer_output, weights_hidden_output)

        #Aplicado a função de ativação
        output = sigmoid(output_layer_in)

#--------------------------------------------

#Cálculo do Erro da Predição
        ## TODO: Cálculo do Erro
        if (output[0]>output[1]):
            if (yi[0]>yi[1]):
                predictions+=1

        if (output[1]>=output[0]):
            if (yi[1]>yi[0]):
                predictions+=1

print("A Acurácia da Predição é de: {:.3f}".format(predictions/n_records))
```

```
A Acurácia da Predição é de: 0.885
```

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]: